智慧物流算法大赛结果分析

南京大学-天才儿童队,程唯,陈立庚

2018年8月13日

本文档仅用于第一届"中储智运"杯智慧物流算法大赛的结果分析。队伍来自南京大学, 天才儿童队。

1 问题简述

对于题目所述问题,主要目的就是根据货物名称,通过分类器给出货物的一级分类、二级分类、三级分类。

由于只有货物名称,没有其他任何特征,因此首先需要从货物名称中提取特征。基于此想法,可以将该问题定位为一个短文本分类问题。

卷积神经网络由于其具有参数共享、自动特征提取等优点,被广泛应用于自然语言处理等领域,因此决定使用卷积神经网络来解决此次比赛中的问题。

2 算法描述

2.1 预处理

货物名称中的数字、字母、特殊字符等对分类的作用不大,因此只保留货物名称中的中文字符即可。

由于货物名称的长度非常短,不好做分词,因此将每个字都分割开作为一个词。

将训练集中每个样本的货物名称都切割完毕之后,统计出现次数最多的前vocab_num个词,以此作为词典 vocab_dict,并添加"UNKNOW"和"BLANK"两个词,分别表示未知词和空白。

2.2 输入表示

设置每一个货物名称的长度为 seq_len, 大于此长度的截断, 小于此长度的用"BLANK"填充, 然后转换成 vocab_dict 中对应的索引。最终一个货物名称以一个索引向量来表示。

设置词嵌入向量的维度为embedding_size,将词嵌入矩阵作为神经网络的参数用来训练,其 shape 为[vocab_num+2,embedding_size]。货物名称对应的索引向量输入神经网络之后,按索引从词嵌入矩阵中提取出对应的词嵌入向量,然后输入卷积层。

2.3 卷积层

参考[1]中的网络结构设计,将卷积层设计为两类。

卷积层A的卷积核作用于每个词的所有维度上,即该类卷积核在词向量维度方向上的尺寸为embedding_size;在词向量之间的 filter_size 分为三种,分别为 1、2、4,即每相邻 1、2、4个词做一次卷积。做完卷积运算后会得到一个向量,再对此向量做最大池化,最终提取出一个特征值。每种卷积核有 filter_num个,因此最终每种卷积核可以得到维度为 filter_num的特征向量。如图 1 展示了该层一个 filter_size 为 2 的卷积核的处理过程。

卷积层 B 的卷积核作用于每个词的一个维度上,即该类卷积核在词向量维度方向上的尺寸为 1,并且一个卷积核只作用于一个维度,即每一维度上都有不同的卷积核;而在词向量之间的 filter_size 和卷积层 A 一样。做完卷积运算之后,一个词的每一维度上都会得到一个向量,对每一维度上的向量做最大池化,最终得到 filter_num 个维度为 embedding_size 的特征向量。如图 2 展示了该层一组 filter_size 为 2 的卷积核的处理过程。

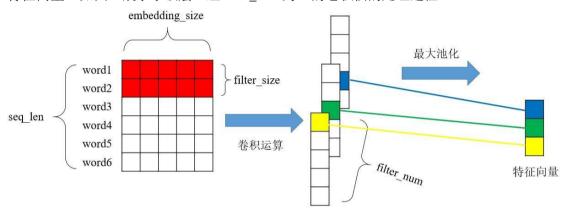


图 1 卷积层 A 处理过程示意图

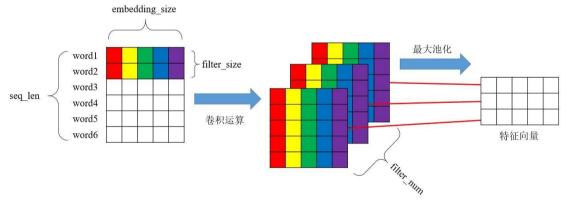


图 2 卷积层 B 处理过程示意图

2.4 全连接层

网络中共有三个全连接层,分别用于计算一级分类、二级分类、三级分类。

将卷积层提取出的所有特征向量拼接在一起构成一个向量 conv_output, 然后直接与第一个全连接层相连即可用于计算一级分类; 将计算出的一级分类也作为一个维度拼接到 conv_output 上, 然后与第二个全连接层相连即可计算二级分类; 将计算得出的一级分类和二级分类都拼接到 conv_output 上, 然后与第三个全连接层相连即可计算三级分类。

3 结果分析

以8比2的比例划分训练集和验证集。

模型训练完毕之后,在验证集上测试其性能。最终,一级分类、二级分类、三级分类全都正确的比例为 0.79 左右,且模型在一级分类上的表现非常好,准确率在 0.96 左右。因此模型性能还算不错。

参考文献

- [1] Hua He, Kevin Gimpel, Jimmy Lin. Multi-Perspective Sentence Similarity Modeling with Convolutional Neural Networks. Conference on Empirical Methods in Natural Language Processing, 2015: 1576-1586.
- [2] Yoon Kim. Convolutional Neural Networks for Sentence Classification. Eprint Arxiv, 2014.